

1.Introduction

현대 야구는 '데이터의 스포츠'라고 불릴 만큼 데이터의 정량적 분석이 경기의 승패를 좌우하는 요소로 자리 잡았다. 특히 투수와 타자간의 승부는 단순한 공 하나의 싸움이 아닌 수많은 승부간이 모여 경기 전체의 흐름을 결정짓는 순간의 연속이다. 과거 머니볼로 대변되는 야구 혁명 이후 세이버메트릭스가 비약적으로 발전해왔지만, 기존의 접근 방식은 여전히 명확한 한계를 가지고 있다.

전통적인 분석은 타율, 출루율, 장타율 그리고 이를 결합한 OPS 등과 같은 결과론적 누적 지표에 주로 의존한다. 이러한 지표들은 선수들의 전반적인 가치를 평가하는데 유용하지만 독립적인 한 경기안에서의 투수 시퀀스나 볼카운트, 주자 상황 등 매 순간 변화하는 동적인 맥락은 반영하지 못하는 한계를 가지고 있다.

2. Related Work

이러한 정적 지표의 한계를 극복하기 위해 최근 야구 분석에서는 XGBoost나 Random Forest와 같은 트리 기반의 머신 러닝 모델들이 적극적으로 도입되었다. 이 모델들은 방대한 양의 투구 추적 데이터를 학습하여 구속, 회전 수, 릴리즈 포인트 등의 물리적인 변수들이 투구 결과에 미치는 비선형적인 관계를 파악하는 데 성공했다. 이를 통해 단순 통계를 넘어선 확률 기반의 예측이 가능해졌으며, 예측 정확도 또한 비약적으로 향상했다. [6]

그러나 이러한 머신러닝 모델 역시 한계에 직면했다. 대부분의 트리 기반 모델은 각 투구를 서로 독립적인 사건으로 간주하여 처리한다. 실제 야구 경기에서 타자의 반응은 직전 투구들의 궤적과 결과에 깊은 영향을 받는 시계열적 특성을 지니고 있다. 즉 XGBoost모델은 현재 투구의 물리적 특성을 잘 파악하지만 '직전에 몸쪽 빠른 공을 보여줘야하기 때문에 이번에는 바깥쪽 변화구에 속을 확률이 높아진다'같은 투구 배합의 시계열적 특성을 학습하기에 한계가 존재한다. [5]

이에 최근 연구는 투구 간의 복잡한 상호작용과 시계열적 의존성을 포착하기 위해 트랜스포머 연구가 도입되었다. 자연어 처리 분야에서 문맥 이해에 혁신을 가져온 트랜스포머의 Self-Attention 매커니즘은 과거의 투구 시퀀스를 하나의 문맥으로 해석한다. 이는 타자가 직전에 어떤 공을 보았는지에 따라 현재 투구에 대한 반응이 달라진다는 점에 착안하여, 과거의 투구 정보가 현재 결과에 미치는 영향을 동적으로 가중치화 할 수 있게 했다. 400구에 달하는 장기 시퀀스를 학습시켜 타자의 고유한 성향과 투구 배합의 패턴을 모델링함으로써, 기존의 정적 통계나 XGBoost등이 포착하지 못했던 시계열적 맥락을

반영하는데 성공했다.[1]

그러나 이 Transformer 연구 모델 연식 실전 적용과 정밀도 측면에서 두가지 구조적인 한계를 드러냈다.

첫째 맥락 정보의 희석이다. 선행 연구는 400구라는 매우 긴 시퀀스를 입력으로 사용했는데 이 과정에서 정작 현재 투구 결과에 가장 중요한 영향을 미치는 즉각적인 경기 상황(볼카운트, 주자 상황, 아웃 카운트 등)의 중요도가 과거의 방대한 데이터에 묻혀 희석되는 경향이 존재한다. 모델이 과거의 경향은 잘 파악하지만 당장의 위기 상황에 대한 민감도는 떨어질 수 있다.

둘째, 데이터 불균형에 대한 대응 부족이다. 야구 데이터는 스트라이크나 볼과 같은 다수 클래스가 홈런, 2루타 같은 희귀 클래스를 압도한다. 선행 연구는 이를 일반적인 손실 함수로 처리하여 경기 성패를 가르는 결정적이고 희귀한 사건에 대한 예측 성능을 충분히 확보하지 못했다.

3. Proposed Method (제안 연구)

이에 본 연구는 선행 연구의 트랜스포머 모델을 계승하면서 앞서 제기된 한계점들을 극복하기 위해 '상황 인식형 트랜스포머(Context-Aware-Transformer)' 모델을 제안한다. 본 연구가 제시하는 핵심적인 개선점은 다음과 같다.

첫째, 맥락 정보의 희석 문제를 해결하기 위해 이원화된 상황 주입 구조를 설계했다. 본 모델은 400구의 긴 시퀀스 대신 최근 8구의 단기 시퀀스에 집중하여 타자의 최신 타격 감각을 반영하였다. 동시에 승부에 결정적인 영향을 끼치는 현재의 경기 상황 정보(볼카운트, 주자 상황)은 복잡한 어텐션 연산을 거치지 않고 출력에 직접 연결되는 스킵 연결(Skip Connection)을 통해 연결한다. 이를 통해 모델은 과거의 패턴을 학습함과 동시에, 당면한 위기 상황을 직관적으로 인지하여 모델 예측에 도움을 줄 수 있다.

둘째, 데이터 불균형 문제를 해소하고 희귀 중요 사건에 대한 예측을 강화하기 위해 Focal Loss를 도입하였다.[2] 기존의 크로스 엔트로피 손실 함수는 다수 클래스인 볼과 스트라이크에 의해 학습이 다수인 경향이 존재한다. 본 연구는 예측 확률이 높은 샘플에 대한 가중치는 낮추고 홈런이나 2루타와 같이 예측이 어렵지만 경기 승패에 직결되는 소수 클래스에 집중하도록 설계된 Focal Loss를 도입하였다. 이를 통해 단순 정확도뿐만 아니라 야구 경기 수립에 중요한 중요 사건의 탐지 성능을 개선하도록 하였다.

4. Methodology

4.1 데이터 구축 및 변수 설정

본 연구에는 2024년 메이저리그(MLB) 정규 시즌의 전체 투구 데이터를 포함하는 MLB

Statcast 데이터셋을 사용하였다.[4] 이 데이터셋은 트랙맨 레이더와 호크아이 카메라 시스템을 통해 수집된 0.01초 단위의 정밀 트래킹 데이터로, 투구의 물리적 특성과 경기 상황을 포괄적으로 포함한다. 데이터셋은 모델의 일반화 성능을 입증하고 실전 전략 수립에 기여하기 위한 목적으로 구축됐으며, 총 데이터 수는 전처리 후 약 62만 건이다.

사전 지식에 근거하여 투구 결과 예측에 필수적인 입력 변수와 출력 변수를 정의했다. 입력 변수는 크게 세 가지 범주인 시퀀스 데이터, 맥락 데이터, 개체 데이터로 구분한다.

시퀀스 데이터는 투구의 흐름을 반영하기 위해 과거 8구의 투구 이력으로 구성했으며, 구속, 회전수, 무브먼트, 로케이션 정보가 포함됐다. 맥락 데이터는 승부에 직접적인 영향을 미치는 현재 시점의 볼카운트, 아웃 카운트, 주자 상황으로 정의됐다. 개체 데이터는 타자와 투수의 고유한 성향을 반영하기 위해 선수 고유 ID와 투구/타석 위치가 선정됐다. 출력 변수는 타격 결과와 투구 판정을 계층적으로 통합하여 총 11개의 클래스(Strike, Ball, Home Run, Single 등)로 재정의됐다. 각 변수의 데이터 타입과 전처리 방식은 아래처럼 구성했다.

구분	변수명	데이터 형태	전처리 방식
Input (X)	Sequence (Past 8 pitches)		
	X1: Release Speed	Continuous	Mean Imputation & MinMax Scaling
	X2: Spin Rate & Direction	Continuous	Mean Imputation & MinMax Scaling
	X3: Plate Location	Continuous	MinMax Scaling
	Context (Current State)		
	X4: Ball/Strike/Out	Discrete	Zero Imputation & Scaling
	X5: Runners on Base	Binary	Zero Imputation (0/1 Mapping)
	Entity (Player Info)		
	X6: Batter/Pitcher	Categorical	Entity Embedding (32-dim)
	X7: Pitch Type	Categorical	Label Encoding & Embedding
Output (Y)	Pitch Outcome	Categorical	11-Class Classification

4.2 모델링 방법

본 연구에서는 투구 시퀀스의 시계열적 의존성과 실시간 경기 상황을 동시에 학습하기 위해, 본인이 설계한 Context Transformer 모델이 사용됐다. 모델의 구현 및 학습은 Python 3.10 환경에서 PyTorch 2.1 프레임워크를 사용하여 수행됐다. 데이터 전처리에는 Scikit-learn의 MinMaxScaler와 LabelEncoder가 활용되었으며, 수치형 변수는 0과 1 사이로 정규화했다.

4.2.1. 엔티티 임베딩 (Entity Embedding)

전통적인 원-핫 인코딩은 차원의 저주를 유발하고 선수 간의 유의미한 관계를 포착하지 못한다는 한계가 있다. 이를 극복하기 위해 타자, 투수, 구종 등 고차원 범주형 변수에 대해 엔티티 임베딩을 적용했다.[3] 각 선수의 고유 ID는 학습 가능한 32차원 밀집 벡터(로 매핑하였고, 모델은 학습 과정에서 오타니와 저지와 같은 특수 선수들의 잠재적 특성

을 벡터 공간 상에 표현하게 된다.

4.2.2. 제안 모델: Context-Aware Transformer

제안된 모델은 이원화된 입력 처리 구조를 특징으로 한다.

첫 번째 경로인 시퀀스 경로에서는 과거 8구의 투구 정보가 임베딩 층을 거쳐 Transformer Encoder로 입력된다. 인코더는 4개의 레이어와 8개의 어텐션 헤드로 구성되며, 셀프 어텐션 메커니즘을 통해 투구 배합의 시계열적 패턴을 추출한다. 이때 모델의 차원은 256으로 설정했다.

두 번째 경로인 맥락 경로에서는 현재 볼카운트와 주자 상황이 별도의 완전 연결층을 통해 32차원 특징 벡터로 변환된다. 이 벡터는 Transformer를 거치지 않고, 스킵 연결을 통해 최종 출력층 직전에 시퀀스 특징 벡터와 결합된다. 이는 긴 시퀀스 처리 과정에서 희석될 수 있는 '현재 위기 상황'에 대한 정보를 보존하기 위함이다.

4.2.3. 손실 함수 및 최적화 (Loss Function & Optimization)

야구 데이터의 고질적인 문제인 클래스 불균형을 해결하기 위해, 본 연구에서는 Focal Loss 를 손실 함수로 채택했다. 포컬 로스는 다음과 같은 식으로 정의되며, 분류하기 쉬운 샘플(예: 아웃, 스트라이크)의 가중치를 낮추고 학습이 어려운 샘플(예: 홈런, 안타)에 집중하도록 설계됐다

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$

본 연구에서는 $r=2.0$ 을 적용하여 희귀 사건에 대한 예측 민감도를 높였다. 최적화 알고리즘으로는 Adam Optimizer가 사용됐으며, 초기 학습률은 0.0005로 설정했다. 학습 안정성을 위해 검증 정확도가 개선되지 않을 경우 학습률을 감소시키는 ReduceLROnPlateau 스케줄러와 Gradient Clipping 기법이 함께 적용하였다.

4.3. 평가 지표 (Evaluation Metrics)

제안된 모델의 성능을 검증하기 위해 전체 데이터셋은 시간 순서에 따라 8:2 비율로 학습 데이터셋과 검증 데이터셋으로 분할했다. 모델의 예측 성능은 Top-1 정확도 (Accuracy)를 주 지표로 사용하여 평가했다. 최종적으로 구축된 모델은 Streamlit 기반의 웹 애플리케이션에 탑재되어 실시간 전략 추천 성능이 정성적으로 평가했다.

5. 모델 결과(model result)

본 연구에서 제안한 상황 인식형 트랜스포머 모델의 유효성을 검증하기 위해 선행 연구 [1]의 방법론을 재현한 베이스라인 모델과 성능을 비교하였다. 베이스라인 모델은 20구의

긴 투구 이력을 입력으로 받아 학습하는 일반적인 트랜스포머 구조를 가지며 동일한 데이터셋에서 약 66%의 정확도를 기록하였다.


반면 본 연구의 제안 모델은 67.52%의 정확도를 달성하며 약 1.52% 향상된 성능을 보여주었다. 이는 맥락 정보를 스킵 연결로 직접 주입하는 개선 방식이 투구 예측 정확도 향상에 기여를 했음을 보여준다.

본 연구의 가장 주목할만한 성과는 입력 데이터의 효율화와 모델의 경량화이다. 비교 군인 베이스라인 모델[1]은 타자의 성향 파악을 위해 과거 20구라는 긴 시퀀스 데이터에 의존해야 했다. 그러나 제안 모델은 8구의 짧은 시퀀스만으로도 베이스라인보다 우수한 성능을 기록했다. 이는 모델이 불필요하게 먼 과거 데이터에 의존하지 않고, 현재 상황과 최근 흐름에 집중하도록 설계한 이유라고 생각한다. 입력 시퀀스 길이가 20에서 8로 60% 이상 감소함에 따라, 어텐션 연산 비용 역시 줄어든다고 판단된다. 이는 실시간성이 중요한 스포츠 데이터 분석 환경에서 모델이 더 적은 리소스로 더 빠르게 추론할 수 있음을 의미하며, 현장 적용 가능성을 높인 결과로 해석된다.

전체적인 정확도 향상뿐만 아니라, 승부처에서의 예측 성능 또한 개선되었다. 특히 볼넷과 삼진 예측 재현율이 베이스라인 대비 유의미하게 상승하였다. 이는 모델이 단순한 구질 분류를 넘어, 투수와 타자 간의 심리적 수싸움을 반영하는 '볼카운트' 정보를 손실 없이 학습했기 때문으로 생각된다.

6. 시스템 구조

본 연구는 제안된 '상황 인식형 트랜스포머' 모델의 실용성을 검증하고, 이를 실제 경기 현장에서 전력 분석원이나 코칭 스태프가 직관적으로 활용할 수 있도록 지원하기 위해 웹 기반의 실시간 투구 전략 추천 시스템을 구현했다.



6.1. 시스템 아키텍처

시스템은 Python 기반의 Streamlit 프레임워크를 사용하여 구축했으며, PyTorch 모델을

엔진으로 탑재하여 구동했다. 전체적인 데이터 처리 및 추론 워크플로우는 다음과 같다.


사용자는 인터페이스를 통해 타자(Batter), 투수(Pitcher), 그리고 현재의 경기 상황(볼카운트, 아웃 카운트, 주자 유무)을 입력한다. 시스템은 입력된 선수 ID를 기반으로 학습된 임베딩 벡터를 호출하여 선수의 고유 성향을 반영한다.

투수가 구사 가능한 8가지 주요 구종(직구, 슬라이더, 커브 등)과 스트라이크 존을 9분할한 코스의 조합을 생성하여, 총 72가지의 가능한 투구 시나리오를 가상으로 시뮬레이션한다.

모델은 각 시나리오에 대해 타자의 예상 반응을 추론한다. 이때, 스트라이크나 범타와 같은 긍정적 결과와 안타나 볼넷 같은 부정적 결과의 확률을 각각 산출한다.

6.2. 시각화 및 현장 적용

분석 결과는 수치 데이터에 익숙하지 않은 야구 관계자들을 위해 포수 시점의 히트맵으로 시각화되어 제공한다. 시스템은 Top3 투구 전략을 시각적으로 강조하여 표시하며, 각 전략에 따른 성공 확률과 리스크를 정량적으로 제시했다.



7. 결론 (Conclusion)

본 연구에서는 현대 야구의 투구 예측 정밀도를 계산하고, 기존 딥러닝 모델이 가진 시계열 맥락 희석 및 연산 비효율성 문제를 극복하기 위해 상황 인식형 트랜스포머를 제안하였다. 2024년 MLB Statcast 데이터를 활용한 실험 및 시스템 구현을 통해 도출된 본 연구의 결론과 의의는 다음과 같다.

첫째, 구조적 개선을 통한 예측 성능의 향상이다. 선행 연구의 방법론을 재현한 베이스라인 모델과 비교하여, 제안 모델은 67.52%의 정확도를 기록하며 성능 향상을 입증하였다. 이는 볼카운트와 주자 상황 같은 핵심 맥락 정보를 트랜스포머의 깊은 레이어에 통과시키지 않고 출력층에 직접 연결하는 '스킵 연결(Skip Connection)' 구조가 정보 소실을 방지하고 예측력을 실질적으로 강화했음을 보여준다.

둘째, 데이터 처리의 효율성 및 모델 경량화의 달성이다. 기존 연구가 타자의 성향 파악을 위해 20구 이상의 긴 시퀀스에 의존했던 것과 달리, 본 연구는 단 8구의 최근 투구 이력만으로도 더 높은 정확도를 달성하였다. 이는 모델이 불필요하게 먼 과거 데이터에 매몰되지 않고 현재의 상황에 집중하도록 한 결과이다. 입력 시퀀스의 대폭적인 축소 (20→8)는 연산 비용 절감으로 이어져, 실시간성이 필수적인 스포츠 현장 분석에 적합한 경량화 모델을 구축하는 데 의의가 있다.

셋째, 실전적 활용 가능성 입증이다. 구축한 모델을 웹 기반의 '실시간 투구 전략 추천 시스템'으로 구현함으로써, 복잡한 딥러닝 모델의 결과를 현장 전문가들이 직관적으로 이해할 수 있는 시각 정보(히트맵, 전략 점수)로 변환하여 제공하였다. 이는 데이터 과학과 스포츠 현장 간의 간극을 줄이는 실질적인 도구로서의 가치를 가진다.

본 연구에서 구축한 투구 예측 모델은 향후 다음과 같은 고도화된 실시간 야구 전략 시스템으로 확장될 잠재력을 가진다.

먼저 모델이 예측한 투구 구종과 코스에 따라 타자의 예상 타구 방향을 실시간으로 결합할 수 있다. 예를 들어, 모델이 '바깥쪽 슬라이더'를 추천할 경우, 타구가 밀려 맞을 확률을 계산하여 내야 수비진을 즉각적으로 이동시키는 수비 시프트 시스템으로 발전 가능하다.

또한 특정 투수가 타자와 승부할 때 모델이 예측한 피안타 위험도가 임계치를 초과하는 빈도가 늘어난다면, 이를 투수의 구위 저하 신호로 해석할 수 있다. 이를 통해 감독에게 데이터에 근거한 최적의 투수 교체 타이밍을 알림을 주는 의사결정 지원 시스템으로 활용할 수 있다.

Reference

- [1] N. Garske and C. Yu, "Transformer-Based Baseball Modeling for Pitch Outcome Prediction and Strategy Optimization," *42 Analytics*, 2025.
- [2] T. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal Loss for Dense Object Detection," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.
- [3] C. Guo and F. Berkhahn, "Entity Embeddings of Categorical Variables," *arXiv*

preprint arXiv:1604.06737, 2016.

[4] MLB Advanced Media, "Statcast Data," *Baseball Savant*, 2024. [Online]. Available: <https://baseballsavant.mlb.com>.

[5] M.-L. Huang and Y.-Z. Li, "Use of Machine Learning and Deep Learning to Predict the Outcomes of Major League Baseball Matches," *Applied Sciences*, vol. 11, no. 10, p. 4499, 2021.

[6] K. Koseler and M. Stephan, "Machine Learning Applications in Baseball: A Systematic Literature Review," *Applied Artificial Intelligence*, vol. 31, no. 9-10, pp. 745-763, 2017.

[7] C. Heaton and P. Mitra, "Learning Contextual Event Embeddings to Predict Player Performance in the MLB," in *The 17th Annual MIT Sloan Sports Analytics Conference*, 2023.